	Politechnika Bydgoska im. Jana i Jędrzeja Śniadeckich Wydział Telekomunikacji, Informatyki i Elektrotechniki Nowoczesne Technologie Przetwarzania Danych Laboratorium 11 Temat: Business Intelligence - wizualizacja i analiza danych w narzędziu Metabase	
---	--	---

Sprawozdanie, Marcin Gregrowicz, semestr VI, grupa nr 1

Cel ćwiczenia

Celem ćwiczenia jest praktyczne poznanie procesu Business Intelligence (BI); załadowanie wcześniej przetworzonych danych do bazy analitycznej; podłączenie narzędzia BI (Metabase) do bazy danych; tworzenie zapytań, wykresów i interaktywnego dashboardu; definiowanie wskaźników (KPI) oraz przygotowanie wyników w formie raportu. Laboratorium pokazuje, jak dane przetworzone we wcześniejszych ćwiczeniach (np. w Apache Spark) zamienić w czytelną informację dla odbiorcy biznesowego.

Link do repozytorium Git:

<https://github.com/MarGegr/NTPD12>

Zadanie 1: Przygotowanie środowiska

Do uruchomienia obu kontenerów został wykorzystany przygotowany plik docker-compose.yml
(został użyty inny port, "5454:5432", by program nie kolidował z lokalnie zainstalowanym Postgresem)

Wersje użytych obrazów

Baza danych: postgres:16 (PostgreSQL 16)

Narzędzie BI: metabase/metabase:lates (Najnowsza stabilna wersja obrazu Metabase)

Docker został poprawnie uruchomiony:

```
(.venv) PS C:\Users\Marcin\Desktop\ARiSzCz\Lab\Kod\NTPD12> docker compose ps
NAME                IMAGE                COMMAND                SERVICE    CREATED        STATUS        PORTS
bi_metabase         metabase/metabase:latest  "/app/run_metabase.sh"  metabase   48 seconds ago  Up 46 seconds  0.0.0.0:3000->3000/tcp, [::]:3000->3000/tcp
bi_postgres         postgres:16          "docker-entrypoint.s..."  postgres   49 seconds ago  Up 47 seconds  0.0.0.0:5432->5432/tcp, [::]:5432->5432/tcp
```

Następnie przeszedłem na <http://localhost:3000/> i stworzyłem swoje konto administratora Metabase.

Zadanie 2: Załadowanie danych do bazy analitycznej


Do tego zadania wykorzystałem dane wygenerowane w poprzednim laboratorium (ale połączyłem je w jeden plik csv, dla ułatwienia). Dane znajdują się w pliku data.csv

Kod tego zadania znajduje się w pliku Zad02.py

Dane zostały poprawnie wczytane do bazy:

```
Wczytywanie połączanego pliku: data.csv
Nawiązywanie połączenia z bazą danych...
Ładowanie danych do tabeli 'transactions'...
Sukces! Dane zostały poprawnie załadowane.
Nazwa tabeli w bazie: transactions
Liczba przesłanych wierszy: 486
```

Następnie byłem w stanie przejrzeć zawartość tej tabeli w Metabase:



The screenshot shows the Metabase web interface. At the top, there is a hamburger menu icon and a logo. Below it, the breadcrumb navigation reads "NTPD / Transactions". A table titled "Transactions" is displayed with the following columns: "Event Time", "User ID", "Category", "Amount", "Status", and a "+" icon for more options. The table contains 8 rows of data.


Event Time	User ID	Category	Amount	Status	+
2026-05-27 14:07:10	u476	electronics	482.19	cancelled	
2026-05-27 14:07:10	u653	electronics	393.92	cancelled	
2026-05-27 14:07:10	u567	electronics	422.05	paid	
2026-05-27 14:07:10	u907	sports	351.29	cancelled	
2026-05-29 00:22:41	u596	sports	229.82	paid	
2026-05-29 00:22:41	u141	clothing	238.91	cancelled	
2026-05-29 00:22:41	u973	sports	495.09	cancelled	

Zadanie 3: Pierwsze pytania (questions) i wykresy


Wizualnym kreatorem stworzyłem zapytanie, które pokazywało liczbę transakcji według ich statusu (anulowane, zapłacone, lub w trakcie). Użyłem wykresu kołowego do

wizualizacji, gdyż taki najlepiej obrazuje ich proporcję.

Liczba przez Status
NTPD / Transactions



Następne pytanie wyświetlało liczbę oraz sumę kwot do transakcji z podziałem na różne kategorie. Zwizualizowałem to za pomocą wykresu słupkowego, gdzie niebieski słupek to liczba transakcji, a zielony to suma kwoty, by pokazać proporcje między tymi dwoma metrykami.



Ostatnie pytanie, zapisane jako kwerenda SQL, pokazywało 5 klientów którzy łącznie wydali najwięcej pieniędzy:

```
SELECT user_id, SUM(amount) AS total_spent
FROM transactions
WHERE status = 'paid'
```

GROUP BY user_id


ORDER BY total_spent DESC

LIMIT 5;

Wyniki zwizualizowałem za pomocą tabeli:

user_id	total_spent
u935	946.16
u998	683.2
u412	655.88
u931	591.62
u232	575.5


Wykonałem też dodatkowe, czwarte pytanie (opisane jako dodatkowe z zadaniu 4) dotyczące trendu sprzedaży w czasie, z podziałem na dzień:




Zadanie 4: Budowa dashboardu

Zbudowałem dashboard korzystając z wizualnego edytora. Na początku zamieściłem łączną liczbę transakcji oraz łączną sprzedaż, a dopiero potem umieściłem wykresy. W dashboardzie wstawiłem 4 karty odpowiadające wyżej opisanym pytaniom. Jako filtr dodałem kategorię transakcji, po wybraniu kategorii wszystkie wykresy i tabela aktualizują się.

Widok:



Po wybraniu kategorii transakcji cały widok automatycznie się aktualizuje i wyświetla poprawne dane:



Opisy teoretyczne

KPI to skrót od angielskiego Key Performance Indicators, czyli Kluczowe Wskaźniki Efektywności. Są to najważniejsze, mierzalne liczby, które firma stale obserwuje, aby szybko ocenić, czy biznes idzie w dobrą stronę i czy realizuje swoje cele. Zamiast przeglądać tysiące pojedynczych zamówień, patrzy się na kilka głównych wskaźników KPI. Przykłady KPI to

Różnica między przetwarzaniem danych a warstwą Business Intelligence

Przetwarzanie danych to wszystko, co dzieje się „pod maską” systemu i jest niewidoczne dla zwykłego użytkownika. Jest to np. pobieranie surowych logów, czyszczenie ich z błędów, naprawianie formatów dat czy naprawianie błędów w bazie danych.

Warstwa Business Intelligence natomiast to „twarz” tego systemu. Pobiera ona te już czyste, poukładane dane z bazy i zamienia je w wizualne wykresy i tabele. Służy do tego, aby menedżer, dyrektor czy właściciel firmy mógł wejść na stronę, zobaczyć jak idzie sprzedaż i podjąć decyzje biznesowe, bez potrzeby wiedzy o programowaniu.


Różnica między dashboardem a raportem statycznym

Raport statyczny to „zdjęcie” danych z jednego, konkretnego momentu w przeszłości. Przykładem jest plik PDF, czy stała tabela. Taki raport pokazuje historię i nie da się w nim nic zmienić, kliknąć ani przefiltrować. By zobaczyć nowe dane, trzeba by wygenerować zupełnie nowy plik.


Dashboard to żywy, interaktywny panel na stronie www, który jest na stałe podłączony do bazy danych i automatycznie się odświeża. Pokazuje on, co dzieje się w tym momencie. Kluczową cechą są interaktywne filtry: użytkownik może kliknąć i wybrać interesującą go kategorię, a wszystkie wykresy na ekranie natychmiast same się przebudują.

Zadanie 5: Wskaźniki, analiza i udostępnianie wyników

Zdefiniowałem dwa wskaźniki KPI (średnia wartość transakcji i udział transakcji opłaconych) oraz umieściłem je na nowym widoku. Wyświetlany jest też stosunek w porównaniu do innego dnia sprzedaży.




Wykonałem też analizę by określić kategorie generujące największy przychód i zwizualizowałem to w postaci wykresu kołowego.



Jak widać na wykresie, sprzęt elektroniczny generował największe przychody, z kolei najgorzej sprzedającą się kategorią były ubrania.

Podobnie zwizualizowałem jak zmienia się sprzedaż w czasie



Udostępnianie wyników: Aby udostępniać wyniki, zapisywałem po prostu stworzone pytania w kolekcji o nazwie NTPD12.

Zapisz jako nowe pytanie



Nazwa

Kategorie generujące największy przychód

Opis

To opcjonalne, ale bardzo pomocne

Gdzie chcesz to zapisać?

 NTPD12



Anuluj

Zapisz